Arquitectura de la plataforma MOOC

Entrega 3: aplicación elástica sobre Google Cloud

Proyecto `proyecto-plataforma-mooc` – Periodo 2026-20

Resumen. La plataforma conserva un backend modular en Go y separa la atención HTTP del procesamiento multimedia. La API, que también sirve la interfaz web, y los workers se despliegan en dos grupos de instancias administrados independientes. PostgreSQL almacena los datos académicos y las sesiones; Redis centraliza las tareas; Cloud Storage conserva los archivos. La elasticidad horizontal se aplica a los procesos de aplicación, mientras que los servicios compartidos delimitan la capacidad y la disponibilidad del conjunto.

Fuentes y alcance. La aplicación se revisó en el repositorio cloud, commit `8a09ca5` del 29 de octubre de 2026. El inventario del 31 de octubre se amplió tras restablecerse el acceso de lectura a Compute: se contrastaron plantillas, red, firewall, balanceador, Registry y secretos por metadata. Durante el inventario inicial los MIG estaban vacíos, las VM detenidas y SQL suspendido. Posteriormente se ejecutó una prueba autorizada de respaldo y restauración en un destino temporal aislado; su medición y cierre se documentan en la sección de recuperación. Las pruebas de carga provienen de JSON del 26 de octubre. Los costos son estimaciones.

Índice

1. Modelo de componentes **2**

2. Modelo de despliegue **4**

3. Decisiones de escalamiento **8**

4. Operación y recuperación **10**

5. Capacidad, costos y limitaciones **13**

A. Fuentes del proyecto y reproducción documental **16**

1. Modelo de componentes

1.1. Responsabilidades y estado compartido

Componente	Responsabilidad	Estado y dependencias
Frontend	SPA React, TypeScript y Vite; flujos de estudiante, profesor y administrador.	Compilada dentro de la imagen y servida por la API. Comparte origen con `/api/v1`.
API Go/Chi	Usuarios, cursos, aprendizaje, evaluaciones, progreso y autorización multimedia.	Repositorios PostgreSQL; Redis para cola, límites de tasa e idempotencia HTTP.
Worker	Tareas Asynq y transcodificación mediante FFmpeg/FFprobe.	Descarga originales, usa temporales locales y publica resultados en objetos; actualiza PostgreSQL.
PostgreSQL	Datos transaccionales y sesiones opacas de autenticación.	Instancia Cloud SQL compartida por todas las réplicas.
Redis	Cola común, reintentos, caché de idempotencia y limitación de solicitudes.	VM independiente de ambos grupos; Compose declara AOF y volumen persistente.
Cloud Storage	Originales, materiales y segmentos HLS; bucket separado para insignias.	Acceso compatible S3 mediante HMAC y URLs firmadas.

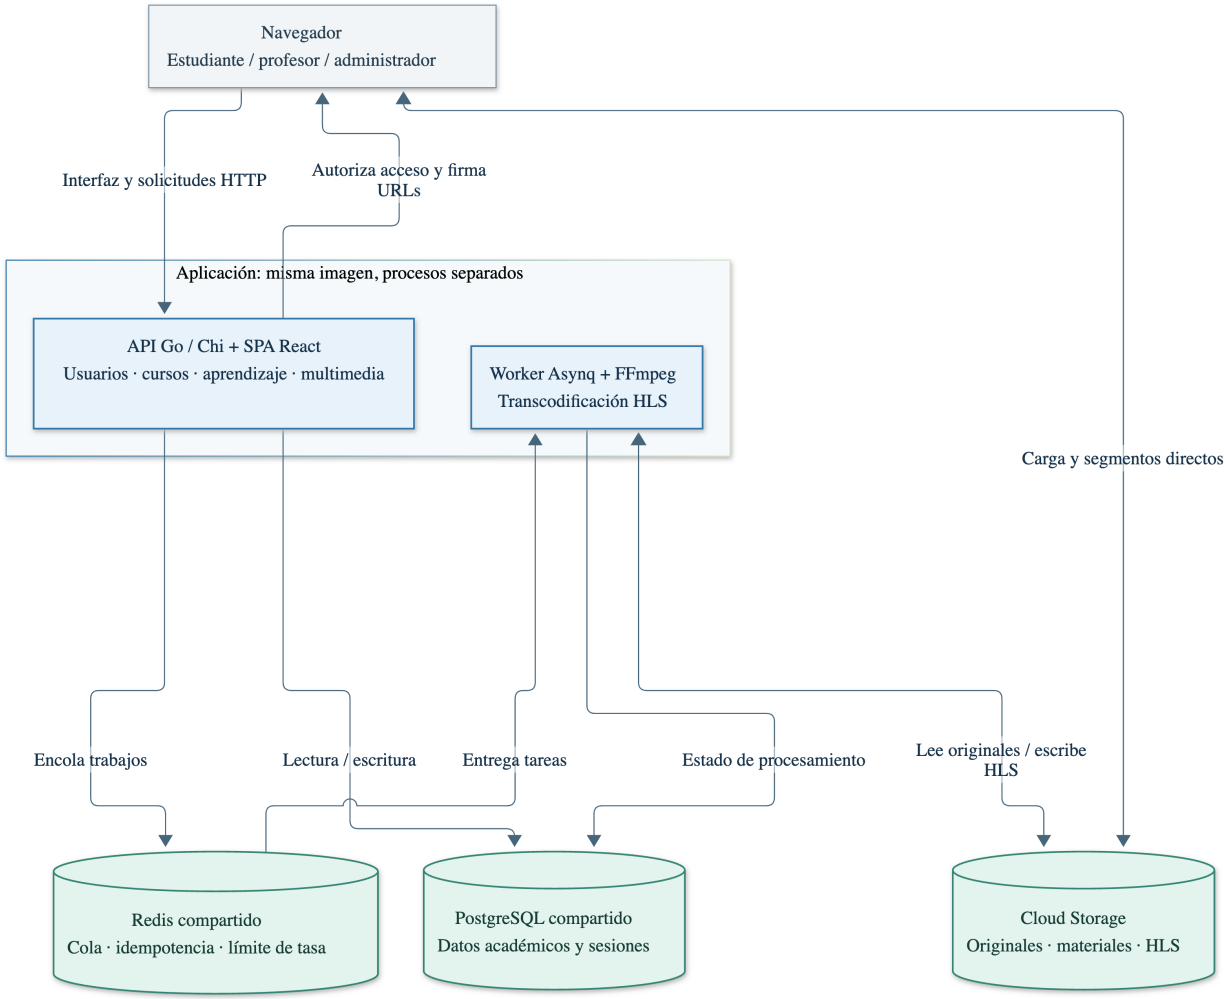


Figura 1: Componentes y comunicaciones. Modelo derivado del código de aplicación.

La API y el worker son procesos diferentes de una misma imagen Docker. La separación ya existía en la Entrega 2; el cambio principal consiste en reemplazar la capacidad fija por grupos independientes y sacar Redis de las instancias reemplazables. La arquitectura sigue siendo un monolito modular con procesamiento asíncrono, sin requerir una división en microservicios.

Las sesiones se consultan en PostgreSQL: no dependen de memoria local ni de afinidad con una réplica. Los temporales del worker no son la copia durable de los archivos. Esta externalización permite reemplazar procesos, pero la integridad durante reemplazos depende también de las transacciones, la finalización de tareas y las políticas de apagado.

1.2. Flujos síncronos y asíncronos

1. **Actividad académica.** Navegador, balanceador y API forman la ruta HTTP. La API autentica la sesión, aplica roles y propiedad del curso y lee o escribe PostgreSQL.
2. **Carga multimedia.** La API autoriza y emite una URL firmada. El navegador carga el archivo directamente a Cloud Storage y confirma mediante `complete-upload`; la API publica la tarea en Redis.
3. **Procesamiento.** Un worker consume la tarea, descarga el original, genera HLS y escribe los resultados en el bucket. El procesamiento de video puede producir 1080p, 720p, 480p y 360p, limitado por la resolución original y sin ampliarla artificialmente.
4. **Reproducción.** La API autoriza el acceso y reescribe manifiestos; los segmentos se transfieren directamente desde objetos al navegador. El tráfico de control y el tráfico binario recorren rutas diferentes.

La interfaz comparte origen con la API; la sesión viaja como `Authorization:Bearer`. CORS de la API se habilita solo si se configura una lista de orígenes. El bucket multimedia sí declara CORS para `https://34.49.211.71`, métodos GET, HEAD y PUT. El frontend no necesita un servicio de hosting separado en esta configuración.

2. Modelo de despliegue

2.1. Topología y recursos observados

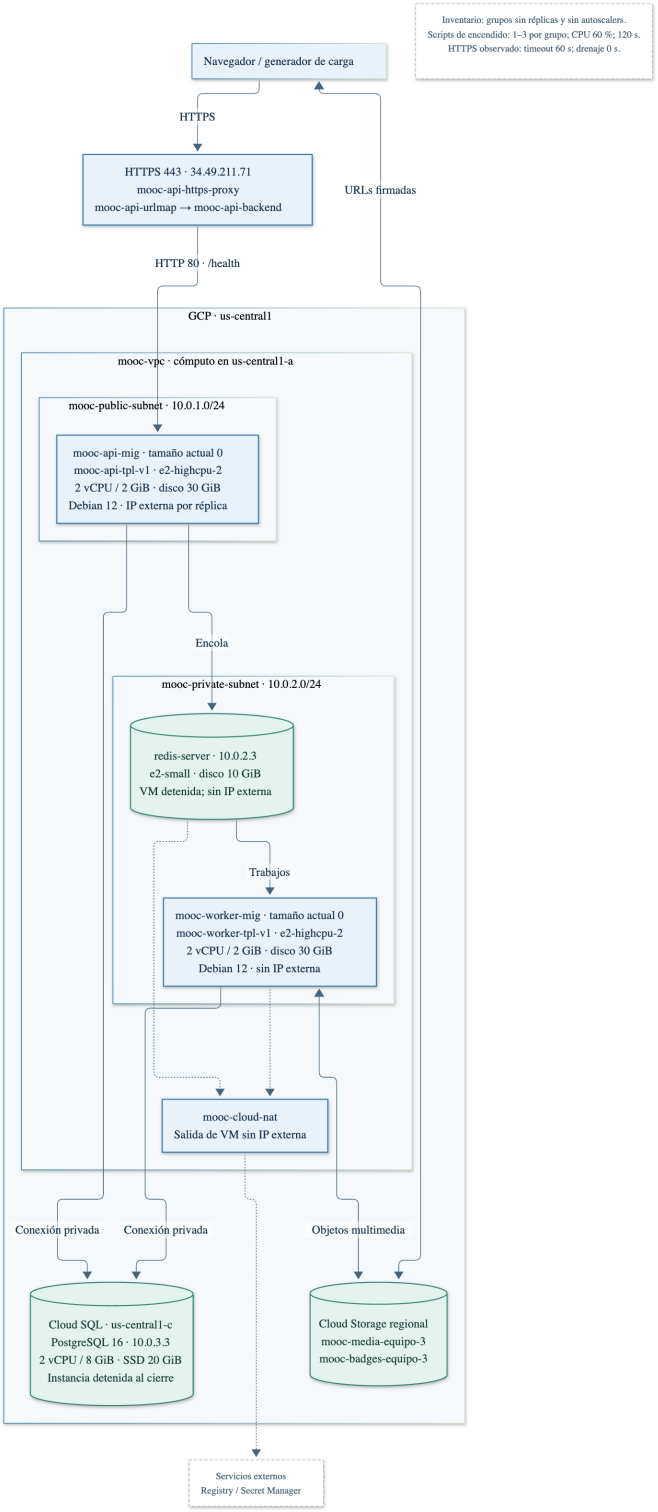


Figura 2: Topología consultada el 31 de octubre, conservada tras la prueba de recuperación. Los grupos permanecen en tamaño cero.

Recurso	Configuración observada en GCP
Entrada	IP global `34.49.211.71`, reglas TCP 80 y 443, esquema `EXTERNAL`. HTTP y HTTPS usan rutas de backend distintas.
API	`mooc-api-mig` y plantilla `mooc-api-tpl-v1`, zona `us-central1-a`; tamaño objetivo y miembros actuales: 0.
Workers	`mooc-worker-mig` y plantilla `mooc-worker-tpl-v1`, misma zona; tamaño objetivo y miembros actuales: 0.
Ambas plantillas	`e2-highcpu-2`: 2 vCPU y 2 GiB; disco de arranque `pd-balanced` de 30 GiB, borrado automático al eliminar réplica; familia Debian 12; aprovisionamiento STANDARD.
Redis	`redis-server`, `e2-small`, 2 GiB y CPU compartida; disco balanced de 10 GiB, Debian 13; IP privada `10.0.2.3`, sin IP externa. Detenido.
Cloud SQL	PostgreSQL 16 Enterprise, 2 vCPU/8 GiB, SSD de 20 GiB, crecimiento automático; zonal `us-central1-c`, privada `10.0.3.3`, sin IPv4 pública. Suspendido por `BILLING_ISSUE` en el inventario inicial; tras el ensayo, nuevamente detenido con política `NEVER`, sin suspensión reportada.
Objetos	`mooc-media-equipo-3` y `mooc-badges-equipo-3`; STANDARD regional en `US-CENTRAL1`.
Generador	`mooc-load-generator`, `e2-standard-4`: 4 vCPU/16 GiB; balanced 40 GiB, Ubuntu 22.04; `10.0.1.12`. Detenido.

Las VM antiguas `web-server` y `worker-server` también existen, detenidas, como `e2-highcpu-2` con discos balanced de 30 GiB. Sus IP privadas son `10.0.1.2` y `10.0.2.2`; Web conserva la IP externa estática `35.209.105.199`. No son miembros activos de los MIG: ambas consultas de miembros devolvieron cero instancias. Sus discos y la IP retenida se consideran por separado en costos.

Las plantillas asocian API a `sa-web` y worker a `sa-worker`, con scope `cloud-platform`; el scope no sustituye los permisos IAM. La API usa la subred pública y declara IP externa efímera Premium; el worker usa la privada sin IP externa. Los tamaños ya están verificados, aunque la ausencia de réplicas activas impide inspeccionar procesos o digests en ejecución.

2.2. Red y reglas de acceso

La VPC personalizada `mooc-vpc` tiene enrutamiento regional y dos subredes de `us-central1`: `mooc-public-subnet` (`10.0.1.0/24`) y `mooc-private-subnet` (`10.0.2.0/24`). Ambas tienen Private Google Access y VPC Flow Logs deshabilitados. Sus nombres no implican por sí solos exposición pública; esta depende de IP y firewall.

El router `mooc-nat-router` contiene `mooc-cloud-nat`, con asignación automática de IP, nivel Standard y cobertura de todas las subredes/rangos. Proporciona salida a las VM sin IP externa; no abre conexiones entrantes. El peering `servicenetworking-googleapis-com` está activo y utiliza la reserva `10.0.3.0/24` para servicios administrados. Existe ruta de salida `0.0.0.0/0` hacia el gateway de Internet.

Regla de ingreso	Origen / destino	Puertos y observación
`allow-web-ingress`	`130.211.0.0/22` y `35.191.0.0/16`; tag `web-server`.	TCP 80, prioridad 1000.
`allow-gcp-health-checks` y `allow-health-checks`	Mismos rangos; sin tag de destino, alcance de toda la VPC.	TCP 80 y 8080. Reglas duplicadas, habilitadas.
`allow-iap-ssh`	`35.235.240.0/20`; sin tag de destino.	TCP 22 para administración vía IAP.
`allow-redis-access`	Ambas subredes; tag `redis-server`.	TCP 6379 privado.
`allow-redis-web-to-worker`	`10.0.1.0/24`; tag `worker-server`.	TCP 6379 heredado del despliegue anterior.

No se observaron reglas clásicas de ingreso abierto desde `0.0.0.0/0` en `mooc-vpc`. Las reglas abiertas de SSH/RDP pertenecen a la red `default`, no a la red de la aplicación. Este inventario de reglas clásicas no equivale a una prueba de conectividad ni a una revisión completa de políticas jerárquicas. SQL exige conexión cifrada; los clientes Redis revisados no configuran autenticación ni TLS.

2.3. Balanceador, salud y autohealing

Las reglas HTTP y HTTPS comparten IP, pero apuntan a proxies y mapas distintos. No se observó redirección HTTP a HTTPS en los mapas exportados.

Parámetro	Entrada HTTPS 443	Entrada HTTP 80
Proxy	`mooc-api-https-proxy`	`mooc-api-http-proxy`
URL map	`mooc-api-urlmap`	`mooc-api-url-map`
Backend service	`mooc-api-backend`	`mooc-api-backend-service`
Protocolo hacia API	HTTP, puerto nombrado `http`=80	HTTP, mismo puerto 80
Timeout	60 s	30 s
Drenaje	0 s	30 s
Sonda	`mooc-api-hc`	`mooc-api-health-check`
Distribución	UTILIZATION, máximo 0,8; sin afinidad de sesión	Mismos valores

Ambos backends apuntan al grupo API y usan `capacityScaler=1`. El objetivo de utilización del backend (80 %) no es el objetivo CPU del autoscaler de los scripts (60 %). El certificado de HTTPS es `mooc-lb-cert`, SELF_MANAGED, con expiración el 16 de octubre de 2027; el repositorio lo describe como autofirmado.

Ambas sondas consultan `/health` por HTTP en el puerto 80, cada 10 s, timeout 5 s, umbral sano 2 y no sano 3. Estos valores corrigen la referencia anterior de 8080/cada 15 s. El startup publica el puerto 80 del host hacia el 8080 del contenedor. La API tiene autohealing con `mooc-api-hc` y retraso inicial de 300 s; el worker no declara política de autohealing. Salud, autohealing, drenaje y autoscaling cumplen funciones diferentes. Las consultas de salud no devolvieron backends individuales porque los grupos están vacíos; no se certifica disponibilidad HTTP actual.

2.4. Identidades, imagen y secretos

El inventario de IAM aportado por Cloud Shell muestra `sa-web` y `sa-worker` con lectura de Registry y escritura de logs/métricas. `github-deployer` tiene administración de instancias, lectura de Compute y permisos anteriores de SSH/IAP. La cuenta predeterminada de Compute mantiene Editor y está asociada a Redis, generador y VM antiguas. No se acredita mínimo privilegio en todas las identidades.

La nueva consulta confirma las identidades de ambas plantillas y el binding `secretAccessor` de `sa-web` sobre `web-server-env` y de `sa-worker` sobre `worker-server-env`. Cada secreto tiene tres versiones habilitadas; el startup pide `latest`. Solo se consultaron nombres, estados y políticas, nunca el contenido. Las políticas de federación y de cuentas de servicio siguen sin consultarse porque la API IAM está deshabilitada para esta consulta.

Las dos plantillas apuntan a `us-central1-docker.pkg.dev/proyecto-plataforma-mooc/mooc/backend:latest`. El startup incorporado coincide byte a byte con el archivo del repositorio. Registry contiene 69 manifiestos/imágenes; la etiqueta `latest` comparte digest con el SHA `8a09ca5`, publicado el 30 de octubre a las 01:23:37 UTC. El digest completo se conserva en `evidencias/detalles-gcp.json`; no se confunde una imagen publicada con una réplica ejecutándola.

El startup escribe `/opt/mooc/app.env` con directorio 700 y `umask077`. Los secretos sí quedan en disco con permisos restrictivos. En los bindings de buckets exportados no aparecen `allUsers`; el acceso es uniforme y hay borrado recuperable de siete días. Las credenciales HMAC y la autenticación SQL son independientes de WIF. No se incluyen valores secretos ni llaves en el documento.

3. Decisiones de escalamiento

3.1. Dos grupos y políticas independientes

La consulta actual de autoscalers devolvió una colección vacía. Ambos MIG tienen tamaño objetivo cero, sin miembros ni acciones pendientes. La siguiente tabla distingue los valores que aplica el script de encendido de la configuración persistente observada en los grupos.

Parámetro	API	Workers
Grupo	`mooc-api-mig`	`mooc-worker-mig`
Tamaño actual	0	0
Política al encender	1–3, CPU 60 %	1–3, CPU 60 %
Inicialización del autoscaler en script	120 s	120 s
Autohealing observado	`mooc-api-hc`, retraso 300 s	Sin política declarada
Actualización de MIG	PROACTIVE, REPLACE	PROACTIVE, REPLACE
Surge / no disponibles	1 / 0	1 / 0
Concurrencia local	Servidor HTTP Go	Configurable; predeterminado 2

Los valores 1–3, CPU 60 % y 120 s están en `scripts/gcp/config.ps1` y los aplica `encender.ps1`. No se presentan como un autoscaler activo durante este inventario. Los 120 s son un parámetro de inicialización, distinto del retraso de autohealing de 300 s y de un tiempo medido de incorporación. El histórico del 25 de octubre registra una limitación de reducción por estabilización de 600 s, descrita más adelante.

Separar grupos permite variar la capacidad HTTP y la capacidad de procesamiento sin obligar a que ambas crezcan al mismo ritmo. CPU es una señal directa para FFmpeg, pero puede reaccionar tarde frente a una acumulación de tareas. Profundidad y antigüedad de cola son señales relevantes

para evaluar una política futura; no están implementadas como métrica de autoscaling en los scripts revisados.

El máximo de tres instancias limita el gasto y la capacidad añadida. Si continúa aumentando la demanda, la API puede aumentar su latencia o rechazar solicitudes, y la cola puede acumular trabajos. SQL y Redis no escalan horizontalmente por esas políticas. Con tres API, el límite configurado de 25 conexiones por proceso permite hasta 75 conexiones de API, a las que se suman workers y operación.

3.2. Plantillas y arranque automático

El mismo startup lee `mooc-role`, `mooc-secret` y `mooc-image` de metadata. Instala Docker si es necesario, autentica la descarga, recupera el entorno y arranca el contenedor correspondiente. No requiere clonar y compilar el repositorio por SSH en cada réplica.

El proceso es repetible en cuanto a reemplazo del contenedor por nombre, pero usa `dockerrm-f`; reiniciar una VM puede interrumpir el trabajo previo. Además, imagen y secreto mediante `latest` son referencias mutables. Aunque el pipeline publica la etiqueta SHA, no actualiza la plantilla a un digest inmutable. Por ello, la igualdad de versión entre réplicas debe comprobarse y no se deduce únicamente del nombre de la plantilla.

La API ejecuta migraciones `.up.sql` en cada arranque, sin un registro de versiones y bloqueo global entre réplicas. La coordinación de migraciones es una limitación de implementación. El handler `/health` devuelve HTTP 200 sin comprobar SQL o Redis: sirve como respuesta de proceso, pero no demuestra disponibilidad funcional de dependencias.

3.3. Retiro de workers y consistencia

El worker usa `srv.Run` de Asynq y reintentos de tareas. El código permite finalizar o reencolar bajo el manejo de señales de la biblioteca, pero no configura explícitamente un tiempo de apagado adaptado a videos largos. El apagado de recursos no comprueba trabajos activos antes de reducir los grupos. Cola pendiente cero tampoco implica ausencia de trabajo en ejecución.

Existe un límite concreto de recuperación multimedia: el worker toma la existencia de `master .m3u8` como señal de finalización y publica archivos por orden de nombre, de modo que puede escribir el master antes de completar los segmentos. Una interrupción en esa ventana puede dejar un resultado parcial que un reintento considere terminado. La integridad del retiro debe verificarse sobre segmentos y estado final, no únicamente sobre existencia del manifiesto.

La idempotencia HTTP usa lectura de caché, ejecución y escritura posterior; no constituye exclusión atómica entre réplicas y la clave no está separada por usuario y ruta. La persistencia compartida de sesiones es una base adecuada para alternar instancias, pero no acredita por sí sola la ausencia de efectos duplicados bajo concurrencia.

3.4. Elasticidad observada en los históricos

Cloud Logging y Monitoring permiten reconstruir un ciclo automático real del grupo de workers el 25 de octubre de 2026. A las 16:22:13 UTC se registró la política ON, mínimo 1, máximo 3, CPU objetivo 60 % e inicialización de 120 s. La siguiente cronología combina decisiones del autoscaler y muestras de tamaño del grupo; todas las horas son UTC.

Hora	Registro	Interpretación
16:26:14	Decisión automática de 1 a 3	Aumento solicitado por el autoscaler.
16:26:28 / 39	Finalización de dos operaciones insert	Creación de VM; no acredita aplicación lista.
16:28:00	Monitoring registra 3 VM	Aumento efectivo de tamaño observado.
16:36:56	Decisión de 3 a 2	Reducción limitada por estabilización de 600 s.
16:38:00	Monitoring registra 2 VM	Primera reducción observada.
16:38:03	Decisión de 2 a 1	Segunda reducción automática.
16:39:00	Monitoring registra 1 VM	Retorno al tamaño inicial.

Entre la decisión de aumento y la primera muestra de tamaño 3 transcurren aproximadamente 106 s. Este intervalo incluye la granularidad de muestreo: no mide bootstrap, disponibilidad del worker ni reacción desde el inicio de la demanda. No se recuperó una reconciliación de tareas que demuestre ausencia de pérdida o duplicación durante el retiro.

Las políticas cambiaron antes de las corridas del 26 de octubre: a las 20:10:10 UTC la API tenía ON, mínimo 1, máximo 3, CPU 60 % e inicialización 60 s; a las 20:11:19 el worker tenía OFF, mínimo 1, máximo 2, CPU 60 % e inicialización 60 s. Hubo recomendaciones de worker de 1 a 2 a las 21:30 y 22:45, pero los eventos indican que no se aplicaron por estar OFF; el grupo permaneció con una VM. Por tanto, los resultados de esas corridas no acreditan beneficios de escalamiento efectivo de workers.

En API se observan aumentos a dos VM que coinciden con actualizaciones del CD. Esa coincidencia no demuestra un ciclo automático causado por carga. La evidencia histórica cubre 13778 muestras de tamaño por grupo entre el 22 y el 31 de octubre; existe una discontinuidad de 187 minutos el día 31, fuera del ciclo documentado. No se extrapola continuidad a ese intervalo.

4. Operación y recuperación

4.1. Despliegue actual y verificación

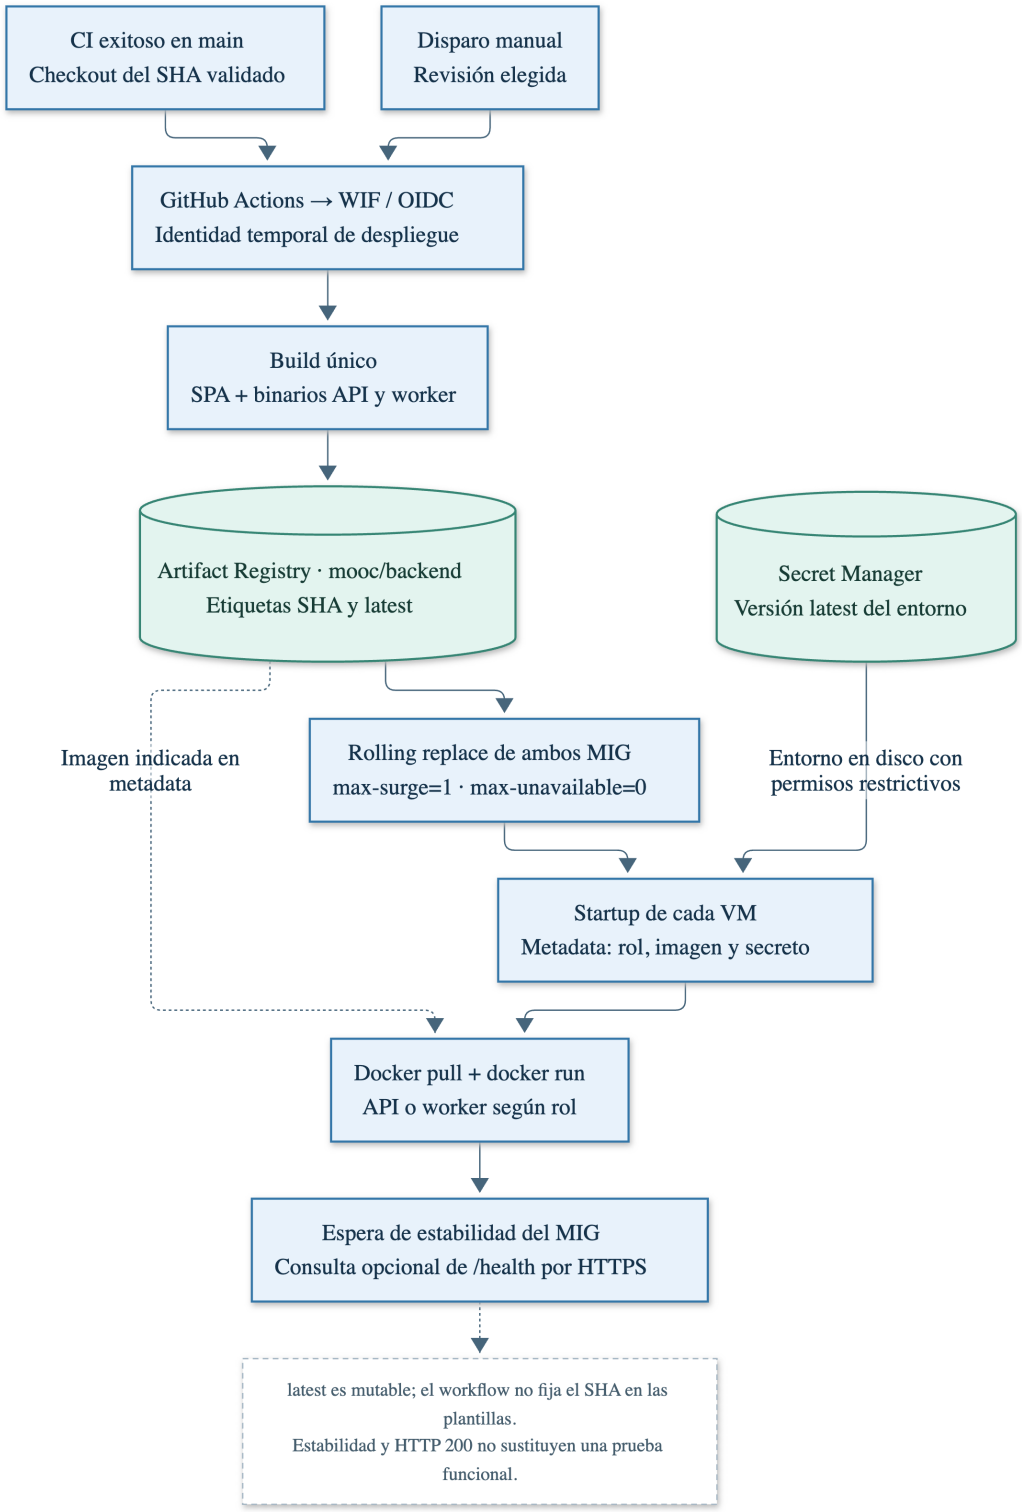


Figura 3: Pipeline y arranque por rol. La publicación de SHA coexiste con el uso operativo de referencias latest.

El detalle operativo se encuentra en `docs/CD.md`, actualizado para reemplazar el procedimiento antiguo por SSH. El flujo implementado es:

1. Finaliza correctamente el CI de `main`; el checkout del CD usa el SHA asociado a ese CI. La ejecución manual existe y no impone por sí sola un CI previo.
2. GitHub obtiene credenciales mediante WIF/OIDC, construye una imagen con SPA, API y worker y publica las etiquetas SHA y `latest` en Artifact Registry.
3. Ejecuta `rolling-actionreplace` en ambos MIG con `max-surge=1` y `max-unavailable=0`; espera estabilidad hasta 900 s por grupo.
4. Si está configurada `GCP_LB_IP`, consulta `/health` hasta 30 veces mediante HTTPS con `curl-k`. Esa comprobación omite validar el certificado y no ejecuta un recorrido funcional.

La aceptación operativa debe verificar versión/digest por réplica, login y lectura/escritura, acceso a objetos y procesamiento de una tarea sintética. Estabilidad del MIG no demuestra por sí misma esas funciones. El pipeline no incluye rollback automático ni serialización explícita de despliegues; una reversión exige una imagen compatible con esquema y secretos, plantillas fijadas a esa versión y validación posterior.

4.2. Encendido, apagado y reconstrucción

Los scripts PowerShell `scripts/gcp/estado.ps1`, `encender.ps1` y `apagar.ps1` consultan u operan recursos existentes. Encender habilita SQL, arranca Redis y aplica las políticas a ambos MIG. Apagar desactiva autoscaling, reduce los grupos a cero, espera estabilidad y apaga dependencias. No equivalen a crear infraestructura desde cero y no deben confundirse con deshabilitar la facturación del proyecto.

Una reconstrucción requiere conservar y aplicar, en orden:

1. Proyecto, APIs, identidades y confianza WIF; VPC, subredes, salida y conectividad privada.
2. Cloud SQL, objetos y Redis persistente; configuración de autenticación y acceso.
3. Imagen identificable en Registry y secretos por rol; plantillas con tamaños, discos, OS, red, identidad y startup.
4. MIG, health checks, backend service, URL map, proxies, certificado y forwarding rules; políticas de autoscaling y reglas de acceso.
5. Verificación funcional y comprobación de integridad antes de habilitar tráfico de usuarios.

El repositorio contiene bootstrap y scripts de operación, pero no un aprovisionador completo con todos esos valores. El inventario adjunto conserva tamaños de plantillas, reglas de firewall y parámetros del balanceador. Sigue faltando una definición ejecutable integral de infraestructura, y la confianza WIF no pudo consultarse. No se promete reconstrucción exacta con un solo comando.

Para retirar recursos de forma controlada, primero se debe impedir nueva carga y reconciliar trabajos activos; luego reducir grupos, detener dependencias y conservar los datos necesarios. El script actual no incorpora todas esas comprobaciones. El borrado definitivo de discos, SQL, buckets o secretos es una operación distinta del apagado y debe prever retención y recuperación.

4.3. Prueba de respaldo y recuperación de PostgreSQL

El 31 de octubre se restauró un respaldo manual de `mooc-db-instance` en la instancia temporal independiente `mooc-db-rpo-rto-test`. El **RPO observado por marcadores fue 131,40 s** y el **RTO de base de datos, 550,59 s (9 min 10,59 s)**. La recuperación está validada para el alcance descrito y la limpieza quedó confirmada a las 18:28:09 UTC.

La conexión se mantuvo privada en la VPC existente, mediante IAP y el generador de carga, con TLS 1.3. Se utilizó el usuario temporal `mooc_recovery_probe` y el esquema `recovery_probe_20261031` dentro de `postgres`. No se redirigió la aplicación al destino de prueba.

Se confirmaron 16 controles sintéticos separados aproximadamente 10,18 s. El respaldo `1793470295023` terminó como `SUCCESSFUL`: inicio 18:11:35.029 UTC y fin 18:13:06.437 UTC, duración de 91,408 s. El incidente fue simulado a las 18:13:52.742666 UTC, sin destruir el origen y antes de crear el destino. La validación terminó a las 18:23:03.377741 UTC. Todas las horas corresponden al 31 de octubre de 2026.

Medición	Resultado y alcance
RPO observado por marcadores	131,402 s, punto medio del intervalo de edad del último COMMIT recuperado: [131,312; 131,492] s.
RTO de base de datos	550,590 s, desde el incidente hasta finalizar validaciones; incluye provisión, restauración, conexión y esperas de control.
Creación del destino	Operación GCP de 18:13:54.983 a 18:16:52.391 UTC: 177,408 s.
Restauración	Operación GCP de 18:17:40.074 a 18:22:39.806 UTC: 299,732 s.
Controles recuperados	Marcadores 1–7, contiguos y con contenido correcto; nueve controles posteriores confirmados no aparecen en el destino.
Aplicación	Nombres, columnas y definiciones de restricciones de 16 tablas iguales entre origen y destino; estructura del origen sin cambios.

Las duraciones se calcularon con un reloj monotónico del controlador. Para el marcador 7, el envío de la transacción y la observación del COMMIT delimitan unos 180 ms de ida y vuelta; de ahí se obtiene el intervalo de edad reportado. Esa incertidumbre es distinta de la resolución de muestreo: el marcador 8, confirmado unos diez segundos después, no se recuperó, por lo que el corte real queda entre los commits 7 y 8. No se equipara la hora de finalización del backup con el punto de recuperación.

El RPO corresponde a este respaldo manual e incidente simulado. No establece un SLO, no garantiza el RPO de respaldos diarios y no valida PITR. El RTO incluye las esperas entre operaciones; no es la suma exclusiva de tiempos informados por GCP. El respaldo previo y la limpieza posterior quedan fuera del cronómetro.

La validación comprobó conexión TLS, controles sintéticos y metadatos de aplicación. El usuario temporal tenía cero tablas de aplicación con SELECT; no se compararon filas, conteos ni checksums de `mooc_db`. Por tanto, se acredita recuperación de PostgreSQL y de los controles, con coincidencia estructural, pero no integridad completa de los datos académicos ni recuperación funcional de API, Redis, workers y archivos.

Cierre verificado. La instancia temporal y el respaldo de prueba quedaron eliminados; el usuario SQL temporal ya no aparece. El generador quedó detenido, con metadata y configuración originales, y se confirmó la retirada del usuario, grupo y directorio SSH temporales. Cloud SQL recuperó su configuración inicial (excepto el contador de versión), con política `NEVER`, nuevamente detenido.

La comparación final confirmó igualdad de nueve colecciones: firewall, redes, subredes, routers, MIG, plantillas, backend services, forwarding rules y URL maps. No se modificó IAM durante la prueba; los roles concedidos por el usuario permanecen asignados y su retiro queda a cargo del propietario. La evidencia consolidada se conserva en `evidencias/recuperacion-20261031.json`, sin credenciales.

5. Capacidad, costos y limitaciones

5.1. Capacidad observada en actividad académica

Se contrastaron los JSON de `loadtests/results/escenario1/20261026_202723_*` con el informe del equipo. La carga se generó desde una VM dedicada en GCP, separada de las máquinas de aplicación. Los niveles documentados usan rampa de un minuto, tres minutos sostenidos y enfriamiento de 30 s; las duraciones efectivas de los JSON incluyen el comportamiento de cierre.

VUs	p95 HTTP (ms)	HTTP/s	Error HTTP	Peticiones	Iteraciones
10	42,89	7,56	0,00 %	2163	1106
50	52,18	30,82	0,00 %	10710	5486
150	146,07	62,32	0,00 %	31338	16135
400	60000,37	19,66	7,34 %	10379	5099
400 (rep.)	60000,11	25,77	5,42 %	13652	6836

Tabla 1: Resultados HTTP del escenario académico. Cada fila es una corrida; no se promedian percentiles.

A 150 VUs se observan 62,32 solicitudes/s y p95 de 146,07 ms, sin errores HTTP registrados. A 400 VUs aparece degradación hasta timeouts de aproximadamente 60 s. El pool SQL es una hipótesis relevante por su carácter compartido, pero no se atribuye causalidad definitiva sin correlación de conexiones, CPU y tiempos de espera de base de datos.

El informe narrativo original confunde 16135 iteraciones con peticiones; los JSON registran 31338 peticiones HTTP. Asimismo, los contadores de rechazos citados corresponden al límite de intentos de quiz, no a una prueba demostrada de doble envío. Un contador de doble calificación igual a cero no acredita el caso cuando no hay evidencia de que se ejercitó el envío.

5.2. Procesamiento y consumo multimedia

VUs carga/reproducción	p95 HTTP (ms)	Espera p95 (s)	Timeouts	Fallos segmentos
1 / 10	91,84	65,68	0	0
3 / 50	75,76	146,40	0	0
5 / 150	78,05	65,96	3	0
10 / 300	80,79	116,82	6	0
10 / 300 (rep.)	74,30	118,41	7	0

Tabla 2: Escenario multimedia, corrida `20261026_224315`. La espera incluye cola, procesamiento y observación por polling.

La métrica `media_processing_duration` mide espera hasta detectar el manifiesto y solo incorpora al percentil los casos que lo detectaron. Los timeouts se cuentan aparte: no es una medición de CPU FFmpeg ni permite afirmar ausencia de fallos de procesamiento. Los segmentos descargados no registran fallos en estas corridas, aunque existen esperas agotadas para nuevos contenidos.

La Entrega 2 reportaba p95 HTTP de 6780,6 ms y 25,44 solicitudes/s a 150 VUs, frente a 146,07 ms y 62,32 en la Entrega 3. Es una comparación descriptiva del informe, no un experimento que aísle autoscaling: se trasladó el generador desde un enlace residencial a GCP y cambiaron elementos de implementación. La descarga directa de HLS mejora el aislamiento del tráfico, pero su velocidad no demuestra que se añadieran workers o API durante la prueba.

5.3. Estimación de costos: una y tres réplicas por grupo

Los valores siguientes son **estimaciones, no facturación observada**. Se usan los tamaños verificados y tarifas públicas bajo demanda de `us-central1`, en USD, consultadas el 31 de octubre de 2026, sin créditos, descuentos ni impuestos. La API de Cloud Billing devuelve `SERVICE_DISABLED`; no se dispone del total cobrado.

Cada API y worker usa `e2-highcpu-2` a 0,04947024 USD/h y un disco balanceado de 30 GiB. Redis usa `e2-small` a 0,016752855 USD/h y disco de 10 GiB. SQL aporta 2 vCPU a 0,0413 USD/h y 8

GiB a 0,007 USD/h, más 20 GiB SSD. Los discos balanceados cuestan 0,000136986 USD/GiB-h y el SSD SQL, 0,000232877 USD/GiB-h.

El modelo incluye las dos reglas globales de balanceo dentro del conjunto de primeras 1–5 reglas, a 0,025 USD/h; una IPv4 externa por API a 0,005 USD/h; y NAT a 0,0014 USD/h por worker y Redis. Se **supone una IP de NAT** a 0,005 USD/h, pues no se verificó su cantidad asignada. Para n réplicas por grupo y h horas de provisión de todos los recursos considerados:

$$C_{\text{base}}(n, h) = h\,(0{,}192780255 + 0{,}11355964\,n).$$

	1 API + 1 worker		3 API + 3 workers	
Partida (USD)	20 h	730 h	20 h	730 h
Cómputo API y workers	1,98	72,23	5,94	216,68
Discos API y workers	0,16	6,00	0,49	18,00
Cómputo Redis	0,34	12,23	0,34	12,23
Disco Redis	0,03	1,00	0,03	1,00
CPU y RAM SQL	2,77	101,18	2,77	101,18
SSD SQL	0,09	3,40	0,09	3,40
Reglas de balanceo	0,50	18,25	0,50	18,25
IPv4 de API	0,10	3,65	0,30	10,95
NAT por VM	0,06	2,04	0,11	4,09
IP de NAT (supuesto: una)	0,10	3,65	0,10	3,65
Total base estimado	**6,13**	**223,63**	**10,67**	**389,43**

Tabla 3: Escenarios de provisión, con totales calculados antes de redondear. No equivalen a una factura del proyecto.

El escenario de 20 h supone que *todos* esos recursos se provisionan durante 20 h. Si solo se detienen las VM y se conservan discos, IP y balanceador durante el mes, sus costos continúan y deben calcularse con sus propias horas. Las 730 h representan operación continua del escenario; no describen el estado actualmente detenido.

Se añaden aparte los componentes ajenos a la base: el generador `e2-standard-4`, con disco de 40 GiB e IP externa, cuesta aproximadamente 2,89 USD por 20 h. Conservar los dos discos heredados de 30 GiB y la IP estática del antiguo web durante 730 h añade aproximadamente 9,65 USD.

Faltan consumos variables: transferencia, operaciones y almacenamiento de objetos, backups, Registry, Secret Manager y observabilidad. Como referencias, NAT procesa datos a 0,045 USD/GiB; balanceo a 0,008 USD/GiB por dirección; GCS regional STANDARD a aproximadamente 0,020 USD/GiB-mes; y backups SQL a 0,08 USD/GiB-mes. La última muestra multimedia registra 5501240159 bytes (5,123 GiB), que costarían aproximadamente 0,10 USD por 730 h si permanecieran constantes, antes de operaciones y transferencia. No hubo serie de insignias: no se asume almacenamiento cero.

Las tarifas proceden de Compute Engine, discos, Cloud SQL, red y balanceo y Cloud Storage. La descarga directa de HLS evita procesar segmentos en el balanceador, pero no elimina el egreso de objetos. El gasto real permanece desconocido.

5.4. Límites de disponibilidad y cierre de evidencias

Redis en una sola VM y Cloud SQL zonal son puntos únicos de falla. Ambos grupos documentados están en una misma zona, por lo que añadir réplicas no constituye recuperación multizona. Las referencias mutables, migraciones concurrentes, health superficial y publicación parcial de HLS limitan las garantías de sustitución transparente.

Evidencia	Estado del documento
Componentes y flujo CD	Contrastados con el código; guía CD actualizada.
SQL, objetos y parte de IAM	Consultados; snapshot conservado sin credenciales.
Plantillas, firewall y LB completo	Inventario efectivo consultado; diferencias entre rutas HTTP/HTTPS registradas.
Capacidad escenarios 1 y 2	Métricas contrastadas con JSON originales; límites del experimento descritos.
Ciclos automáticos 3A/3B	Ciclo worker del 25 de octubre acreditado; API por carga y retiro íntegro de trabajos no acreditados.
Costos	Modelo de dos escenarios y tarifas de referencia; gasto real no disponible.
Backup/restauración y RPO/RTO	Respaldo manual restaurado: RPO por marcadores 131,40 s; RTO de base de datos 550,59 s. Alcance y límites documentados.

A. Fuentes del proyecto y reproducción documental

- Arquitectura base y informe de capacidad.
- Workflow CD, startup, políticas y Redis externo.
- JSON escenario 1 y JSON escenario 2; corridas identificadas en las tablas.
- API y salud, worker y procesamiento HLS.
- Inventarios saneados de Compute, SQL, objetos, Registry e IAM, junto con históricos de Monitoring y auditoría en `evidencias/`. Se excluyen credenciales y valores secretos.